

FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

PROYECTO MIA

PROPUESTA DEL PROYECTO DE TITULACIÓN

MODELO INTELIGENTE DE PREDICCIÓN DE MORA BANCARIA MEDIANTE MACHINE LEARNING EXPLICABLE PARA LA GESTIÓN DEL RIESGO CREDITICIO

AUTOR1: GARCÍA MORA FÉLIX ANTONIO

AUTOR2: OLMEDO CORONEL ANDRÉS MARCELO

AUTOR3: SUASNAVAS GUTIERREZ IBETH LILIANA

CONTENIDO

1. Título del proyecto 3
2. Descripción del problema o necesidad 3
   2.1 Árbol del problema y trazabilidad de impacto 3
   2.2 Definición operativa de la variable objetivo 4
   2.3 Mapa de actores y estrategia de participación 4
   2.4 Alternativas de solución y selección justificada 4
3. Objetivo general 5
4. Objetivos específicos 5
5. Justificación, viabilidad, recursos y riesgos 6
   5.1 Justificación 6
   5.2 Recursos mínimos 6
   5.3 Riesgos de implementación y respuesta 6
6. Propuesta de solución 7
   6.1 Alcance funcional del MVP 7
   6.2 Pipeline de datos y modelado 8
   6.3 Arquitectura y MLOps 8
   6.4 Modelos candidatos y regla de selección 8
   6.5 Métricas y criterios de aceptación 9
   6.6 Explicabilidad, equidad y supervisión humana 9
   6.7 Cronograma referencial del módulo de titulación 9
   6.8 Matriz RACI de entregables 10
7. Datos del proyecto 10
   7.1 Perfil verificable de la base piloto 10
   7.2 Diccionario de datos preliminar 10
   7.3 Protocolo de calidad, desbalance y validación 12
   7.4 Anonimización, seguridad y gobierno 13
8. Referencias 14
9. Firmas de responsabilidad 15

1. Título del proyecto

Modelo inteligente de predicción de mora bancaria mediante Machine Learning explicable para la gestión del riesgo crediticio en Banco ProCredit.

2. Descripción del problema o necesidad

Banco ProCredit requiere fortalecer la priorización de la cartera en el Área de Recuperación, donde la revisión histórica y las reglas de negocio no ofrecen una estimación temprana, homogénea y explicable del riesgo por cliente-operación. La base piloto disponible contiene 8.399 registros y 14 variables observadas, mientras el inventario institucional esperado reúne 33 variables; por tanto, 19 variables aún deben incorporarse y validarse. Además, se identificaron 2.325 filas exactamente repetidas (27,68 %) y faltantes en exp_sf (21,79 %), linea_sf (13,42 %) y deuda_sf (5,49 %). Estas condiciones afectan la trazabilidad, la representatividad y la confiabilidad del modelado si no se controlan. El problema central es la capacidad limitada para identificar, priorizar y explicar, antes del horizonte de incumplimiento, qué operaciones alcanzarán una de las seis categorías de mora. Sus causas incluyen la ausencia de una etiqueta temporal aprobada, datos sin identificador ni fecha de corte, posibles fugas de información y falta de un pipeline reproducible y monitoreable. El impacto potencial se refleja en una asignación ineficiente de gestores, mayor exposición a cartera vencida y decisiones menos auditables. Como aún no se dispone de una línea base institucional de recuperación, costos y tiempos, el proyecto la medirá durante el piloto y no asumirá ahorros no demostrados. Si no se interviene, persistirá una gestión reactiva y no será posible evaluar objetivamente la mejora frente a las reglas actuales.

La solución se delimita a un piloto académico con datos autorizados. La procedencia, temporalidad y cobertura histórica serán aprobadas por el custodio de datos antes del entrenamiento definitivo.

2.1 Árbol del problema y trazabilidad de impacto

Nivel	Elementos verificables
Causas	Procesos manuales y reactivos; reglas no calibradas; ausencia de pipeline reproducible; calidad y procedencia de datos no formalizadas; falta de monitoreo de desempeño, sesgo y drift.
Problema central	Capacidad limitada para identificar, priorizar y explicar anticipadamente qué clientes presentan mayor probabilidad de mora dentro de un horizonte operativo definido.
Efectos	Mayor exposición a cartera vencida; costo de gestión elevado; asignación ineficiente de gestores; menor tasa de recuperación; decisiones menos trazables y mayor riesgo de sesgo o incumplimiento normativo.

El impacto no se confundirá con la precisión del modelo. Durante el piloto se medirá: distribución por categorías de mora, saldo expuesto (EAD), severidad de pérdida (LGD), monto recuperado, tasa de recuperación, costo por gestión, tiempo promedio por caso, Macro-F1, Recall por categoría y Lift para la capacidad real del equipo. El beneficio financiero incremental se estimará como: recuperación adicional del grupo priorizado menos recuperación del grupo de comparación menos costo operativo incremental. Si EAD, LGD o costos no están disponibles, el resultado se reportará como brecha de información y no como ahorro supuesto.

2.2 Definición operativa de la variable objetivo

Elemento	Definición propuesta	Control requerido
Objetivo del modelo	mora: variable categórica ordinal con seis niveles: 0 = al día; 1 = 1-7 días; 2 = 8-30 días; 3 = 31-60 días; 4 = 61-90 días; 5 = más de 90 días.	Validar con el propietario de datos la fecha de corte, horizonte, regla de creación, curas, castigos y reestructuraciones.
Horizonte institucional	mora_h90: categoría máxima de mora alcanzada dentro de los 90 días posteriores a la fecha de corte t0, usando los seis niveles definidos.	Aprobar el horizonte y las reglas de transición con Recuperación/Riesgos; reconstruir la etiqueta desde eventos fechados.
Unidad de análisis	Un cliente-operación en una fecha de corte definida.	Incorporar identificador seudonimizado, id de operación y fecha de corte.
Prevención de fuga	Solo usar variables disponibles antes o en t0; todas las ventanas históricas deben cerrarse antes del inicio del horizonte objetivo.	Auditar especialmente atraso, score, clasif_sbs, máximos/eventos de mora y reestructuraciones; excluir o rezagar si existe fuga.

2.3 Mapa de actores y estrategia de participación

Actor	Categoría / poder-interés	Participación prevista
Área de Recuperación / gestores	Usuario interno / Alto-Alto	Co-diseñar prioridades, validar explicaciones y ejecutar UAT.
Riesgos de crédito	Decisor técnico / Alto-Alto	Aprobar etiqueta, umbrales, métricas y restricciones de uso.
Custodio de datos / TI	Proveedor interno / Alto-Alto	Autorizar fuentes, documentar procedencia y controlar accesos.
Oficial de Protección de Datos y Seguridad	Control interno / Alto-Medio	Revisar base jurídica, DPIA, minimización y seguridad.
Superintendencia de Bancos del Ecuador	Regulador / Alto-Medio	Marco de supervisión prudencial; mantener satisfecha e informada mediante evidencia auditable.
Clientes de crédito	Actor afectado / Bajo-Alto	Proteger derechos, evitar trato adverso y asegurar supervisión humana.
Equipo de proyecto y tutor	Ejecutor académico / Medio-Alto	Construir, documentar, verificar y aprobar entregables académicos.

2.4 Alternativas de solución y selección justificada

Criterio (peso)	Reglas mejoradas	ML binario explicable	ML ordinal multiclase + MLOps
Desempeño y priorización (30 %)	2/5	4/5	5/5
Explicabilidad y auditoría (20 %)	5/5	4/5	4/5
Adecuación a seis niveles de mora (20 %)	2/5	1/5	5/5
Reproducibilidad y monitoreo (15 %)	2/5	3/5	5/5
Viabilidad en 12 semanas (15 %)	5/5	5/5	4/5
Puntaje ponderado / 5	3,05	3,40	4,65

Decisión	Justificación	Control
Seleccionada: ML ordinal multiclase explicable con MLOps	Obtiene 4,65/5 y representa directamente las seis categorías de mora; combina capacidad predictiva, explicabilidad, reproducibilidad y monitoreo.	Comparar contra reglas actuales y línea base logística bajo las mismas particiones; no promover si incumple seguridad, equidad o aceptación operativa.

3. Objetivo general

Desarrollar y validar un sistema inteligente de predicción temprana de mora para priorizar la recuperación de cartera, mediante aprendizaje automático explicable y un MVP reproducible y monitoreable, en Banco ProCredit.

4. Objetivos específicos

Objetivo específico	Entregable verificable	Criterio de aceptación	Sem.
OE1. Analizar, durante las semanas 1 y 2, los requerimientos, la procedencia y la calidad de las 33 variables para aprobar el diccionario, la unidad cliente-operación y la etiqueta ordinal mora_h90, documentando el 100 % de variables, faltantes, duplicados, desbalance y riesgo de fuga.	Diccionario de 33 variables, ficha de procedencia, EDA, informe de calidad y especificación de mora_h90.	100 % de variables descritas; seis categorías, unidad y horizonte aprobados; brechas y fugas documentadas.	1-2
OE2. Diseñar, durante las semanas 3 y 4, la arquitectura reproducible de datos, entrenamiento, inferencia y monitoreo del MVP, verificando el versionamiento con DVC, el registro de experimentos con MLflow y la construcción de una imagen Docker sin errores críticos.	Diagrama de arquitectura, repositorio, pipeline, plan de pruebas y controles de seguridad.	Pipeline reproducible; datos/modelos versionados; experimentos registrados; imagen Docker funcional.	3-4
OE3. Implementar y comparar, durante las semanas 5 y 6, una regresión logística multinomial u ordinal y cuatro modelos de ensamble, mediante validación estratificada y temporal sin fuga, registrando semillas, hiperparámetros, artefactos y métricas para seleccionar el candidato con mayor utilidad predictiva y operativa.	Línea base y experimentos con Random Forest, XGBoost, LightGBM y CatBoost.	Cinco familias evaluadas bajo el mismo protocolo; comparación reproducible y selección justificada.	5-6
OE4. Evaluar, durante las semanas 7 y 8, el desempeño, la calibración, la robustez, la equidad y la	Informe ISO/IEC 25059, matriz de métricas multiclase/ordinales, model card y reportes SHAP.	Umbrales cumplidos o desviaciones justificadas; análisis por subgrupos y explicación completa.	7-8

explicabilidad del modelo seleccionado, comprobando los umbrales del apartado 6.5 y generando explicaciones SHAP para el 100 % de las predicciones válidas del conjunto de prueba.			
OE5. Integrar y validar, durante las semanas 9 a 12, el modelo en un MVP con FastAPI y Streamlit, logrando latencia p95 menor o igual a 2 segundos, aprobación del 100 % de casos UAT críticos, monitoreo de drift y un procedimiento de rollback probado.	API, interfaz, registro de consultas, alertas, manuales y acta UAT.	Predicción y explicación por caso; p95 <= 2 s; UAT críticos aprobados; rollback disponible.	9-12

5. Justificación, viabilidad, recursos y riesgos

5.1 Justificación

La predicción temprana de mora puede concentrar la capacidad limitada de cobranza en los casos con mayor probabilidad y valor de intervención, reduciendo tiempos improductivos y mejorando la trazabilidad. En un dominio regulado, la utilidad exige equilibrar desempeño y comprensión: SHAP permitirá explicaciones locales y globales, mientras que una regresión logística multinomial u ordinal funcionará como referencia interpretable (Lundberg & Lee, 2017; Bussmann et al., 2021; Bücker et al., 2022). El sistema será de apoyo y no ejecutará decisiones automáticas de crédito o cobranza; el gestor conservará la decisión final y podrá registrar una discrepancia justificada.

La factibilidad analítica inicial es favorable: la base piloto contiene 8.399 observaciones y 14 variables demográficas, laborales, financieras y de comportamiento, mientras que el inventario ampliado incorpora 19 variables históricas y derivadas adicionales. La evaluación preliminar anterior obtuvo ROC-AUC de 0,731 para regresión logística y 0,799 para Random Forest bajo una codificación binaria; estos resultados no son comparables directamente con la nueva variable objetivo categórica de seis niveles. El entrenamiento definitivo deberá reconstruir la etiqueta, incorporar las variables ampliadas, aplicar partición temporal y reportar métricas multiclase y ordinales sin fuga de información.

5.2 Recursos mínimos

Recurso	Especificación mínima	Uso
Equipo humano	Tres integrantes; enlace de Recuperación/Riesgos; custodio de datos; usuario validador.	Gobierno, datos, modelado, MLOps, interfaz y UAT.
Cómputo	CPU de 4 núcleos, 16 GB RAM, 20 GB libres; GPU opcional.	Suficiente para 8.399 registros y modelos tabulares; la GPU no es requisito del MVP.
Software	Python 3.11+, pandas, scikit-learn, XGBoost, LightGBM, CatBoost, SHAP, MLflow, DVC, FastAPI, Streamlit, Docker y Git.	EDA, entrenamiento, explicabilidad, API, interfaz y reproducibilidad.
Seguridad	Entorno segregado, cifrado en tránsito/reposo, control de acceso por rol, secretos fuera del código y bitácora.	Protección de datos y auditabilidad.

5.3 Riesgos de implementación y respuesta

Riesgo	Prob.	Impacto	Mitigación	Evidencia
Procedencia o granularidad no confirmada	Alta	Alta	Acta de fuente, dueño, periodo, unidad y diccionario; reconciliar cifras institucionales con la base piloto.	Ficha firmada y consulta reproducible.
Privacidad y confidencialidad	Media	Alta	Minimización, seudonimización, acceso por rol, cifrado, retención definida y evaluación de impacto.	Matriz LOPDP, permisos y bitácora.
Duplicados y datos faltantes	Alta	Alta	Distinguir repetición legítima de duplicado; imputación dentro del pipeline; indicadores de ausencia y pruebas de sensibilidad.	Reporte de calidad antes/después.
Fuga de información	Alta	Alta	Auditoría temporal de atraso, score, clasif_sbs, máximos/eventos de mora y reestructuraciones; exclusión o rezago; validación cronológica.	Checklist de leakage, disponibilidad en t0 y pruebas de ablación.
Desbalance multiclase y umbral inadecuado	Alta	Media	Class weights/remuestreo solo dentro de folds; Macro-F1 y Recall por clase; umbral definido por capacidad y costo; calibración multiclase.	Matriz de confusión, curvas por categoría y matriz de costos.
Sesgo por subgrupos	Media	Alta	Evaluar TPR, FPR, precision y calibración uno-contra-resto por edad, zona y educación; supervisión humana y registro de override.	Informe de equidad y mitigación.
Drift y degradación	Media	Alta	PSI/JS, estabilidad de score y desempeño por ventana; alertas, champion-challenger y rollback.	Dashboard, alertas y registro de versión.
Resistencia al cambio	Media	Media	Co-diseño de Streamlit, capacitación, explicación por caso y UAT con gestores.	Acta UAT y encuesta de utilidad.
Sobrecarga para tres integrantes	Media	Media	MVP acotado, roles claros, backlog priorizado y automatización esencial.	Cronograma, tablero y definición de terminado.

6. Propuesta de solución

6.1 Alcance funcional del MVP

Dentro del alcance: preparación y validación de datos autorizados; entrenamiento y comparación de modelos; explicabilidad SHAP; API FastAPI; interfaz Streamlit; monitoreo inicial; pruebas técnicas y UAT con usuarios designados. Fuera del alcance: integración con el core bancario, infraestructura definitiva, decisiones automáticas de crédito o cobranza, despliegue productivo a escala, adquisición de datos sin autorización y ejecución automática de acciones sobre clientes. El MVP recibirá registros validados, estimará probabilidades por categoría, asignará una prioridad configurable y conservará versión, fecha, umbral y explicación.

Actor	Caso de uso	Salida
Gestor de Recuperación	Consultar riesgo y explicación de un cliente-operación.	Probabilidades por categoría, prioridad, factores SHAP y advertencias de calidad.
Analista/Riesgos	Cargar lote y revisar ranking top-K.	Listado priorizado, distribución por categorías, métricas de cobertura y exportación controlada.

Administrador del modelo	Revisar versión, drift, desempeño y alertas.	Panel de monitoreo, historial de experimentos y decisión de rollback/reentrenamiento.

6.2 Pipeline de datos y modelado

Etapa	Actividad	Control de salida
1. Ingesta	Lectura versionada desde zona segura; esquema y hash de archivo.	Versión DVC, checksum, conteo y procedencia.
2. Validación	Tipos, dominios, rangos, faltantes, duplicados y consistencia temporal.	Pruebas automáticas y reporte de calidad.
3. Preparación	Separación train/valid/test; imputación, codificación, escalado y tratamiento de desbalance multiclase dentro de folds.	Pipeline sin contaminación entre particiones.
4. Entrenamiento	Línea base multinomial/ordinal y modelos multiclase con búsqueda controlada de hiperparámetros.	Semillas, parámetros, código y métricas en MLflow.
5. Evaluación	Desempeño multiclase y ordinal, calibración, robustez, equidad, estabilidad y SHAP por categoría.	Informe comparativo y model card.
6. Registro	Aprobación del champion y almacenamiento de artefactos.	Modelo, firma, versión, dependencias y criterios de promoción.
7. Servicio	API FastAPI y Streamlit dentro de Docker.	Pruebas unitarias, integración, seguridad y latencia.
8. Monitoreo	Calidad de entrada, drift, desempeño tardío, sesgo y uso.	Alertas, rollback y regla de reentrenamiento.

6.3 Arquitectura y MLOps

Flujo lógico: fuente histórica segura -> validación y features -> entrenamiento/validación -> registro de modelo -> API de inferencia -> interfaz Streamlit -> monitoreo y retroalimentación. La separación entre datos, código, modelo y servicio reduce deuda técnica y facilita auditoría (Sculley et al., 2015; Kreuzberger et al., 2023).

Componente	Herramienta	Artefacto mínimo
Versionamiento	Git + DVC	Código, punteros a datos, pipeline y versiones reproducibles.
Experimentos	MLflow	Parámetros, métricas, curvas, modelo y firma.
Empaquetado	Docker	Imagen versionada, dependencias fijadas y prueba de arranque.
Inferencia	FastAPI	Endpoint autenticado, esquema de entrada/salida y manejo de errores.
Interfaz	Streamlit	Consulta individual/lote, probabilidades por categoría, ranking, explicación y advertencias.
Monitoreo	MLflow + registro de métricas	Calidad, PSI/JS, distribución de score, desempeño y equidad.

6.4 Modelos candidatos y regla de selección

Modelo	Rol	Fortaleza	Control
Logística multiclase	Línea base obligatoria	Interpretabilidad, probabilidades por categoría y auditabilidad.	Regularización, multicolinealidad, supuesto ordinal y calibración.
Random Forest	Candidato multiclase	No linealidad y robustez tabular.	Sobreajuste, tamaño y calibración.
XGBoost	Candidato multiclase	Alto desempeño, control de regularización y TreeSHAP.	Búsqueda acotada, early stopping y SHAP.

LightGBM	Candidato multiclase	Eficiencia de entrenamiento.	Complejidad de hojas y sobreajuste.
CatBoost	Candidato multiclase	Tratamiento de variables categóricas.	Codificación ordenada y consistencia de categorías.

La selección no se fijará por preferencia previa. Se aplicará validación cruzada estratificada y, cuando existan fechas, validación temporal con test fuera de tiempo. El modelo promovido deberá superar la línea base de regresión logística multinomial u ordinal en utilidad predictiva y operativa sin degradar injustificadamente explicabilidad, equidad, seguridad, latencia o mantenibilidad. La evaluación seguirá el modelo de calidad de ISO/IEC 25059:2023 y la gestión de riesgos de ISO/IEC 23894:2023.

6.5 Métricas y criterios de aceptación

Dimensión	Métrica	Umbral inicial de aceptación
Discriminación	ROC-AUC y PR-AUC uno-contra-resto	Macro ROC-AUC >= 0,75; reportar promedio macro/ponderado y resultado por cada categoría.
Clasificación	Macro-F1, Weighted-F1 y Recall por categoría	Macro-F1 >= 0,70 y Recall >= 0,80 para las categorías 3, 4 y 5; reportar intervalos de confianza.
Priorización	Recall@K y Lift@K para mora severa	Lift > 1 y superior a reglas actuales para el K operativo; documentar la definición de mora severa.
Calibración	Brier multiclase, log-loss y ECE	ECE <= 0,10 o recalibración justificada; comparar contra la línea base y mostrar curvas por categoría.
Equidad	Brecha TPR/FPR/precision uno-contra-resto	Brecha absoluta <= 0,10 entre subgrupos con n suficiente; si no se cumple, mitigar o restringir uso.
Explicabilidad	Cobertura y estabilidad SHAP por categoría	Explicación local para 100 % de predicciones válidas; estabilidad global por categoría entre folds.
Robustez	Stress tests multiclase	Sin caída > 5 puntos porcentuales de Macro-F1 o Recall de clases severas ante perturbaciones plausibles.
Servicio	Latencia p95 y pruebas críticas	p95 <= 2 s en entorno MVP; 0 fallos críticos de seguridad/validación; rollback probado.
Drift	PSI/JS, distribución de categorías y desempeño	PSI < 0,10 estable; 0,10-0,25 alerta; > 0,25 revisión. Alerta por caída > 5 puntos en Macro-F1 o Recall severo.

6.6 Explicabilidad, equidad y supervisión humana

SHAP se usará para explicar contribuciones globales y por registro para cada categoría de mora, contrastando las explicaciones con lógica financiera y evitando presentar asociación como causalidad (Lundberg & Lee, 2017; de Lange et al., 2022). La interfaz mostrará probabilidades por categoría, banda de prioridad, factores principales, versión y advertencias. Para equidad se evaluarán métricas uno-contra-resto por grupos de edad, zona y nivel educativo cuando el tamaño muestral lo permita, siguiendo el principio de igualdad de oportunidad como referencia (Hardt et al., 2016). No se usarán atributos sensibles para trato adverso; su eventual uso de auditoría requerirá base jurídica y acceso restringido.

6.7 Cronograma referencial del módulo de titulación

Semanas	Actividad principal y responsable (R)	Hito
1	R: García Mora; C: Riesgos/custodio. Gobierno, requerimientos, procedencia y etiqueta.	Acta de alcance y datos.
2	R: Suasnavas Gutierrez; C: custodio. Diccionario, EDA, calidad y leakage.	Informe de datos aprobado.
3	R: Olmedo Coronel. Pipeline reproducible y línea base logística.	Línea base multiclase registrada.
4-5	R: Olmedo Coronel + García Mora. Modelos candidatos, validación y ajuste.	Tabla comparativa de modelos.

6-7	R: Suasnavas Gutierrez + Olmedo Coronel. Calibración, equidad, robustez y SHAP.	Informe ISO/IEC 25059 y model card.
8	R: García Mora + Olmedo Coronel. DVC, MLflow, Docker, API y pruebas.	Servicio reproducible.
9	R: Suasnavas Gutierrez. Interfaz Streamlit y flujo de usuario.	MVP funcional.
10	R: García Mora; A: equipo. UAT, drift, seguridad y rollback.	Acta de pruebas y ajustes.
11-12	R: los tres autores; A: García Mora. Informe, manuales, repositorio y defensa.	Entrega completa.

6.8 Matriz RACI de entregables

Entregable	R / A	C / I
Problema, actores, objetivos y alcance	R/A: García Mora; R: Suasnavas	C: tutor y contraparte; I: Olmedo
Datos, diccionario y EDA	R/A: Suasnavas; R: Olmedo	C: custodio/Riesgos; I: García Mora
Modelos y evaluación	R/A: Olmedo; R: García Mora	C: tutor/Riesgos; I: Suasnavas
MVP, UAT y monitoreo	R/A: García Mora; R: Olmedo y Suasnavas	C: gestores, TI y DPO; I: tutor
Informe y defensa	R/A: García Mora; R: Olmedo y Suasnavas	C: tutor; I: contraparte

7. Datos del proyecto

7.1 Perfil verificable de la base piloto

Indicador	Resultado	Implicación
Cobertura de variables	8.399 filas x 14 variables observadas; inventario objetivo de 33 variables	Incorporar y validar las 19 variables adicionales antes del entrenamiento definitivo.
Variable objetivo	La base piloto conserva codificación binaria; Variables.pdf define seis categorías (0-5)	Reconstruir la etiqueta categórica desde eventos fechados; no reutilizar métricas binarias como resultado final.
Duplicados exactos	2.325 filas (27,68 %)	No eliminar automáticamente: pueden ser repeticiones legítimas al faltar identificador/fecha.
Faltantes	exp_sf 21,79 %; linea_sf 13,42 %; deuda_sf 5,49 %	Imputación dentro de folds, indicador de ausencia y análisis de mecanismo.
Cobertura geográfica	25 zonas; Lima concentra 4.980 registros (59,29 %)	Evaluar representatividad, agrupación de categorías raras y estabilidad por zona.
Temporalidad	Sin fecha de corte ni fecha de evento	Impide validación fuera de tiempo y confirmación de horizonte; campo obligatorio para la base definitiva.

7.2 Diccionario de datos preliminar

Las definiciones siguientes reproducen y operacionalizan las 33 variables del archivo Variables.pdf. Los nombres se mantienen sin modificación; los tipos, unidades, ventanas temporales, fórmulas, catálogos y disponibilidad en t0 deberán ser validados por el custodio de datos antes del modelado.

Variable	Tipo	Rol	Definición operativa preliminar	Control específico
mora	Categórica	Objetivo (ordinal)	Categoría de mora: 0 = al día; 1 = 1 a 7 días; 2 = 8 a 30 días; 3 = 31 a 60 días; 4 = 61 a 90 días; 5 = más de 90 días.	Confirmar fecha de corte, horizonte, fuente y reglas para reestructuraciones, castigos y curas.

atraso	Numérica	Predictora candidata	Número de días de atraso en una obligación crediticia.	Alto riesgo de fuga; usar únicamente el valor disponible en la fecha de corte t0.
vivienda	Categórica	Predictora	Condición de vivienda: propia, alquilada, familiar, hipotecada u otra.	Homologar categorías y evaluar su posible efecto proxy o de sesgo.
edad	Numérica	Predictora/auditoría	Edad del cliente expresada en años.	Validar rango y consistencia; evaluar desempeño y equidad por grupos.
dias_lab	Numérica	Predictora	Cantidad de días laborados o antigüedad en el empleo actual.	Confirmar unidad, fecha de cálculo y tratamiento de interrupciones laborales.
exp_sf	Numérica	Predictora	Experiencia en el sistema financiero, medida en meses o años.	Confirmar unidad, fecha de cálculo y mecanismo de valores faltantes.
nivel_ahorro	Numérica/ Categórica	Predictora	Nivel o saldo de ahorro, expresado como valor, rango o categoría.	Definir unidad o catálogo y evitar mezclar códigos ordinales con montos.
ingreso	Numérica	Predictora	Ingreso mensual o anual declarado por el cliente.	Confirmar moneda, periodicidad, fecha de actualización y tratamiento de extremos.
linea_sf	Numérica	Predictora	Monto total de líneas de crédito aprobadas en el sistema financiero.	Confirmar moneda, fecha de corte, cobertura y mecanismo de faltantes.
deuda_sf	Numérica	Predictora	Monto total de deuda vigente en el sistema financiero.	Confirmar moneda, fecha de corte, cobertura y mecanismo de faltantes.
score	Numérica	Predictora candidata	Puntaje crediticio utilizado para medir riesgo de incumplimiento.	Documentar metodología, versión y disponibilidad previa al evento para controlar fuga.
zona	Categórica	Predictora/auditoría	Zona geográfica de residencia o actividad económica.	Homologar el ámbito geográfico, agrupar categorías raras y revisar efecto proxy.
clasif_sbs	Categórica	Predictora candidata	Clasificación de riesgo: Normal, CPP, Deficiente, Dudoso o Pérdida.	Validar catálogo y fecha de actualización; excluir si incorpora información posterior.
nivel_educ	Categórica	Predictora/auditoría	Nivel educativo: primaria, secundaria, superior, posgrado u otro.	Homologar categorías y justificar necesidad, base jurídica y uso para auditoría de equidad.
mora_max_3m	Numérica	Predictora histórica	Máximo número de días de mora registrado en los últimos 3 meses.	Construir la ventana antes de t0 y verificar que no incluya el período objetivo.
mora_max_6m	Numérica	Predictora histórica	Máximo número de días de mora registrado en los últimos 6 meses.	Construir la ventana antes de t0; revisar redundancia con mora_max_3m y mora_max_12m.
mora_max_12m	Numérica	Predictora histórica	Máximo número de días de mora registrado en los últimos 12 meses.	Construir la ventana antes de t0 y documentar cobertura histórica completa.
atrasos_6m_12m	Numérica	Predictora histórica	Número de eventos de atraso registrados durante los últimos 6 meses.	Reconciliar el nombre con la ventana de 6 meses indicada en el PDF y evitar solapamiento temporal.
atrasos_12m	Numérica	Predictora histórica	Número de eventos de atraso registrados durante los últimos 12 meses.	Definir qué constituye un evento, deduplicar episodios y construir la ventana antes de t0.
dti	Numérica (%)	Predictora derivada	Relación deuda total/ingreso; mide la	Fijar periodicidad y unidades; controlar ingreso

			carga financiera del cliente.	cero, faltantes, valores extremos y fecha de corte.
cuota_ingreso	Numérica (%)	Predictora derivada	Relación entre la cuota mensual de pago y el ingreso mensual.	Definir qué cuotas se agregan y controlar ingreso cero, moneda, periodicidad y extremos.
saldo_promedio_3m	Numérica (monetaria)	Predictora histórica	Promedio de saldos en cuentas o depósitos durante los últimos 3 meses.	Confirmar moneda, cuentas incluidas, frecuencia y ventana cerrada antes de t0.
variacion_depositos_ingresos	Numérica (%)	Predictora derivada	Variación porcentual de depósitos o ingresos frente a un período anterior.	Documentar fórmula, períodos comparados y tratamiento de denominador cero o faltante.
num_entidades_deuda	Numérica	Predictora	Número de entidades financieras con obligaciones crediticias activas.	Definir entidad activa, fuente consolidada, deduplicación y fecha de corte.
nuevos_creditos_3m_6m	Numérica	Predictora histórica	Cantidad de nuevos créditos adquiridos durante los últimos 3 meses.	Reconciliar el nombre con la ventana de 3 meses indicada en el PDF y evitar conteos duplicados.
nuevos_creditos_6m	Numérica	Predictora histórica	Cantidad de nuevos créditos adquiridos durante los últimos 6 meses.	Definir fecha de apertura, productos incluidos y ventana cerrada antes de t0.
porcentaje_utilizacion_linea	Numérica (%)	Predictora derivada	Porcentaje de uso de la línea: saldo utilizado/línea de crédito aprobada.	Controlar línea cero, valores superiores al 100 %, moneda y fecha de corte.
saldo_pendiente_credito	Numérica (monetaria)	Predictora	Saldo actual pendiente de pago de las obligaciones crediticias.	Confirmar moneda, componentes incluidos y disponibilidad exacta en t0.
cuotas_restantes	Numérica	Predictora	Número de cuotas pendientes para cancelar totalmente el crédito.	Definir tratamiento de cuotas vencidas, períodos de gracia, castigos y reestructuraciones.
tipo_credito	Categórica	Predictora	Producto crediticio: consumo, vivienda, vehicular, productivo, comercial, microcrédito, agropecuario, educativo o tarjeta.	Usar catálogo institucional versionado y controlar categorías nuevas o múltiples productos.
antiguedad_cliente_banco	Numérica (meses o años)	Predictora	Tiempo desde la vinculación inicial del cliente con el banco.	Definir unidad, fecha inicial, reingresos y cálculo respecto de t0.
numero_productos_banco	Numérica	Predictora	Número total de productos financieros contratados con la entidad.	Definir productos activos, catálogo, deduplicación y fecha de corte.
reestructuraciones_refinanciamientos_previos	Binaria	Predictora histórica	Indica si existieron reestructuraciones o refinanciamientos previos: sí/no.	Normalizar codificación, confirmar anterioridad a t0 y revisar implicaciones de fuga y trato adverso.

7.3 Protocolo de calidad, desbalance y validación

- Separar primero train, validación y test; todo ajuste, imputación, codificación, selección y remuestreo se aprende únicamente con train.
- Investigar los 2.325 duplicados exactos mediante identificadores y fechas. Si representan la misma entidad, aplicar split agrupado; si son copias técnicas, conservar un registro con trazabilidad de la depuración.
- Imputar numéricas con estrategia robusta dentro del pipeline y añadir indicador de ausencia cuando sea informativo; comparar con análisis de casos completos.

- Tratar el desbalance multiclase con class weights y, solo como experimento, remuestreo dentro de los folds. Reportar Macro-F1, Weighted-F1, Recall por categoría, matriz de confusión y sensibilidad al umbral operativo.
- Cuando existan fechas, usar entrenamiento histórico, validación posterior y test fuera de tiempo; nunca mezclar observaciones futuras en el entrenamiento.
- Realizar pruebas de ablación y disponibilidad temporal para atraso, score, clasif_sbs, mora_max_3m, mora_max_6m, mora_max_12m, atrasos_6m_12m, atrasos_12m y reestructuraciones_refinanciamientos_previos; excluir o rezagar cualquier variable que incorpore información posterior a t0.

7.4 Anonimización, seguridad y gobierno

La base piloto no contiene nombres, cédulas, teléfonos o correos visibles, pero edad, zona, nivel educativo y las variables laborales, financieras, históricas y de comportamiento del inventario ampliado son datos personales o cuasi-identificadores. Se aplicarán minimización, propósito específico, seudonimización de identificadores, separación de la llave de reidentificación, cifrado, acceso por rol, bitácora, retención limitada y eliminación segura. Cualquier dato usado para auditoría de equidad permanecerá segregado y no será una entrada del servicio sin justificación jurídica. El tratamiento observará la Ley Orgánica de Protección de Datos Personales y las políticas internas aplicables.

Artefacto de gobierno	Responsable	Condición de cierre
Ficha de procedencia y base jurídica	Custodio + equipo	Fuente, finalidad, periodo, permisos, unidad y retención aprobados.
Diccionario y catálogo	Datos + Riesgos	Definición, tipo, unidad, fórmula, ventana, disponibilidad temporal y dueño para el 100 % de las 33 variables.
DPIA/evaluación de impacto	Privacidad/Seguridad	Riesgos, controles, acceso y residual aprobados antes del piloto.
Model card	Equipo de IA	Uso previsto, limitaciones, datos, métricas, sesgos, versión y responsables.
Registro de decisiones	Usuario/Riesgos	Predicción, explicación, override y resultado posterior auditables.

8. Referencias

Asamblea Nacional del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales. Registro Oficial, Quinto Suplemento No. 459, 26 de mayo de 2021.

Bayram, F., Ahmed, B. S., & Kassler, A. (2022). From concept drift to model degradation: An overview on performance-aware drift detectors. Knowledge-Based Systems, 245, 108632. https://doi.org/10.1016/j.knosys.2022.108632

Bücker, M., Szepannek, G., Gosiewska, A., & Biecek, P. (2022). Transparency, auditability, and explainability of machine learning models in credit scoring. Journal of the Operational Research Society, 73(1), 70-90. https://doi.org/10.1080/01605682.2021.1922098

Bussmann, N., Giudici, P., Marinelli, D., & Papenbrock, J. (2021). Explainable machine learning in credit risk management. Computational Economics, 57, 203-216. https://doi.org/10.1007/s10614-020-10042-0

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

de Lange, P. E., Melsom, B., Vennerød, C. B., & Westgaard, S. (2022). Explainable AI for credit assessment in banks. Journal of Risk and Financial Management, 15(12), 556. https://doi.org/10.3390/jrfm15120556

Fritz-Morgenthal, S., Hein, B., & Papenbrock, J. (2022). Financial risk management and explainable, trustworthy, responsible AI. Frontiers in Artificial Intelligence, 5, 779799. https://doi.org/10.3389/frai.2022.779799

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. In Advances in Neural Information Processing Systems (Vol. 29, pp. 3315-3323). Curran Associates, Inc.

Hovakimyan, G., & Bravo, J. M. (2024). Evolving strategies in machine learning: A systematic review of concept drift detection. Information, 15(12), 786. https://doi.org/10.3390/info15120786

International Organization for Standardization & International Electrotechnical Commission. (2023a). ISO/IEC 23894:2023 Information technology - Artificial intelligence - Guidance on risk management. ISO.

International Organization for Standardization & International Electrotechnical Commission. (2023b). ISO/IEC 25059:2023 Software engineering - Systems and software Quality Requirements and Evaluation (SQuaRE) - Quality model for AI systems. ISO.

Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. IEEE Access, 11, 31866-31879. https://doi.org/10.1109/ACCESS.2023.3262138

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In Advances in Neural Information Processing Systems (Vol. 30, pp. 4765-4774). Curran Associates, Inc.

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. In Advances in Neural Information Processing Systems (Vol. 28, pp. 2503-2511). Curran Associates, Inc.

9. Firmas de responsabilidad

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
FELIX ANTONIO
GARCIA MORA

AUTOR 1: GARCÍA MORA FÉLIX ANTONIO

FECHA: 03/08/2026

ANDRES MARCELO OLMEDO CORONEL

Firmado digitalmente por ANDRES MARCELO OLMEDO CORONEL
Fecha: 2026.08.19 22:01:09 -05'00'

AUTOR 2: OLMEDO CORONEL ANDRÉS MARCELO

FECHA: 03/08/2026

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
IBETH LILIANA
SUASNAVAS GUTIERREZ

AUTOR 3: SUASNAVAS GUTIERREZ IBETH LILIANA

FECHA: 03/08/2026